

**TEKNOFEST**  
**HAVACILIK, UZAY VE TEKNOLOJİ FESTİVALİ**  
**SAĞLIKTA YAPAY ZEKÂ YARIŞMALARI**  
**(Bilgisayarlı Görüyle Abdomen (Karın) Bölgesi için**  
**Hastalık Tespiti Kategorisi)**  
**PROJE DETAY RAPORU**

**TAKIM ADI: FEZA**

**TAKIM ID: 320507**



## **İÇİNDEKİLER**

<b>1. PROJE MEVCUT DURUM DEĞERLENDİRMESİ.....</b>	<b>3</b>
<b>2. ÖZGÜNLÜK.....</b>	<b>6</b>
<b>3. SONUÇLAR VE İNCELEME.....</b>	<b>7</b>
<b>4. DENEY VE EĞİTİM AŞAMALARINDA KULLANILAN VERİ SETLERİ.....</b>	<b>9</b>
<b>5. REFERANSLAR.....</b>	<b>10</b>

## **TABLolar**

Tablo 1: Testler sonucunda en başarılı model versiyonlarının özellikleri.....	4
Tablo 2: Model kombinasyonlarının başarı testi sonuçları.....	7
Tablo 3: Tasarlanan ve seçilen modellerin patoloji tespit testi başarıları.....	8
Tablo 4: Sağlık bakanlığı veri seti analizi.....	9

## **ŞEKİLLER**

Şekil 1: Tasarlanan ve yarışmada kullanılacak olan patoloji tespit algoritması.....	5
---	---

## 1. PROJE MEVCUT DURUM DEĞERLENDİRMESİ

Sağlıkta yapay zeka yarışması kapsamına uygun olarak başarılı bir patoloji tespit algoritması tasarlayabilmek için proje sunuş raporunda belirtilen hedeflere ulaşıldı ve testler yapıldı.

İlk hedef yarışmada kullanılacak olan algoritmanın tasarlanmasıydı. Algoritma tasarımı 3 ana parçada incelendi; bunlar backbone, neck ve head bölümleridir. Proje sunuş raporunda belirtildiği üzere hazır modeller kullanmaktan kaçınıldı ve görev odaklı algoritma modelleri tasarlandı. Bu modellerin tasarlanması için MMDetection [1] aracı kullanıldı. MMDetection, birçok güncel nesne tespit algoritmalarını içeren, bu algoritmalar üzerinde özgürce değişiklik yapılabilen ve yeni algoritmalar eklenebilen açık kaynaklı bir araçtır. Backbone için 2 aday vardı; bunlar Visual Attention Network (VAN) [2] ve ConvNeXt [3] algoritmalarıydı. Her iki algoritma da aslında sınıflandırma algoritmalarıdır. Tam bağlı katmanları kaldırıldı ve birden fazla çıkış alabilmek için kodlarında değişiklikler yapıldı. Açık kaynaklı olan her iki algoritma da MMDetection sistemine uygun bir şekilde düzenlendi ve sisteme backbone olarak eklendi. Oluşturulacak olan modelin neck adaylarından olan Bidirectional Feature Pyramid Network (BiFPN) [4] MMDetection sistemine entegre edilebilecek şekilde düzenlendi ve sisteme neck olarak eklendi. Path Aggregation Network (PANet) [5] MMDetection aracında bulunduğu için hazır olarak kullanıldı. Modelin head adayları olan T-head [6] ve YOLO-head [7] ise PANet'te olduğu gibi MMDetection sisteminde bulunduğu için hazır olarak kullanıldı. Proje sunuş raporunda belirtilen bu algoritmalar backbone-neck-head olarak çeşitli kombinasyonlarda birbirlerine uyumlu olacak şekilde MMDetection ortamında birleştirildi. Örnek olarak ConvNeXt, PANet ve T-head birleştirilerek yeni bir patoloji tespit algoritması tasarlandı.

Diğer bir hedef ise algoritmanın eğitiminde ve test aşamasında kullanılacak veri setinin oluşturulmasıydı. Sağlık bakanlığı tarafından verilen veri seti, algoritma eğitim ve testlerine uygun hale getirildi. Veri setinde bulunan DICOM verileri incelendi. En uygun Hounsfield Units (HU) [8] aralıkları, sağlık bakanlığı tarafından sağlanan DICOM dosyalarındaki HU değerlerine göre seçildi. Genelleme performansını artırma ve daha doğru patoloji tespiti yapabilme açısından proje sunuş raporunda belirtildiği üzere incelenmiş olan makalelerde başarıyı artıran HU değerleri de dikkate alındı. Böylece iki farklı HU aralıkları belirlendi; bunlar [50, 400] ve [-600, 1500] değerleridir. 2 farklı HU aralığı belirlenmesinin sebebi girdinin çeşitliliğini artırarak problem olarak sunulan her patolojinin tespitini en doğru şekilde gerçekleştirmektir. Örnek olarak [50, 400] HU aralığında bulunamayan patoloji, diğer belirlenen HU aralığında olabilir. Patolojiyi kaybetmeme açısından böyle bir yöntem kullanıldı. DICOM verileri hakkında bilgiler içeren sağlık bakanlığı tarafından sağlanan veri setinde bulunan excel dosyası incelendi. Excel dosyasından alınan bilgilerle DICOM görüntülerinin etiket bilgileri YOLO formatında [9] txt dosyalarına çevrildi. Her görüntü için ayrı olarak oluşturulan txt dosyaları patoloji sınıfı id numarası ve patolojinin görüntüdeki koordinatlarını içerir. Sağlık bakanlığı tarafından verilen excel dosyasında koordinatlar (x1, y1, x2, y2) şeklindeydi ancak YOLO formatına uygun olması açısından koordinatlar (x, y, w, h) formatına çevrildi. Her patoloji sınıfı ayrı olarak gruplandırıldı ve bazı sınıfların eğitim için yeterli sayıda veri içermediği kararlaştırıldı. Bu problemi ortadan kaldırmak, veri çeşitliliğini artırmak ve eğitilecek algoritmanın genelleme performansını artırmak için veri çoğaltma (augmentation) algoritması geliştirildi. Proje sunuş raporunda belirtilmeyen bu yöntem tasarlanarak kullanıldı.

Veri çoğaltma algoritması geliştirilirken hem görüntüler hem de etiket dosyaları dikkate alındı. Görüntüde yapılan değişikliğin etkisi görüntünün etiket dosyasına da yansıtıldı. Çeşitli veri çoğaltma yöntemleri kullanıldı; bunlar flip, rotate, blur, CLAHE, exposure ve brightness

yöntemleridir. Tasarlanan veri çoğaltma algoritması belirlenen yöntemlerin gerçekleşme olasılıkları ayarlanarak rastgele kombinasyonlarda istenilen sayıda görüntü ve görüntülerin etiketlerini oluşturacak şekilde yazıldı.

Daha sonra elde edilen veriler COCO [10] standartlarına göre tekrar düzenlendi, çünkü MMDetection sistemi bu standartları destekliyor. YOLO formatına çevrilen txt etiket dosyaları COCO json formatına çevrildi ve MMDetection sistemine uygun hale getirildi. En başta YOLO formatının kullanılmasının sebebi, YOLO formatında koordinatlar görüntü boyutunun oranına göre belirlendiği için üzerinde işlem yapılması daha kolay hale gelmesidir. Böylece veri çoğaltma aşamasında etiketleri çoğaltma sırasında daha az zahmet çekildi.

Veri seti ve model kombinasyonları hazırlandıktan sonra aday olarak seçilen algoritmalarından en doğru model kombinasyonunun hangisi olduğunu belirlemek için eğitim ve testler yapıldı. Deneme amaçlı yapılan bu eğitim ve testler veri setinden seçilen böbrek-üreter taşı patolojileri içeren görüntüler ile yapıldı. Proje sunuş raporunda ve sonuçlar ve inceleme kısmında bahsedilen algoritma kombinasyonları denendi ve en başarılı kombinasyon, patoloji tespit algoritmasında kullanmak üzere seçildi. Seçilen patoloji tespit modeline literatürde örneği olmadığı için Feza ismi verildi.

Proje sunuş raporuna ek olarak, problemin çözümünde kullanmak üzere yeni yöntem belirlendi. Yarışma sırasında DICOM serilerinin hangi abdomen bölgesini içerdiği bilgisi verileceği için her patoloji sınıfı ayrı olarak değerlendirildi. Tespit edilmesi beklenen 6 sınıf için 6 farklı model eğitilmesi kararlaştırıldı. Böylece özellikle yanlış pozitif yani, o bölgede bulanamayacak patolojilerin model tarafından varmış gibi etiketlenmesi durumlarının önüne geçilmesi ve daha isabetli koordinat tahminleri yapan algoritmanın tasarlanması amaçlandı. Veri Seti bu yöntemle göre oluşturuldu ve model eğitimleri bu şekilde gerçekleştirildi.

Model	Backbone	Neck	Head	Derinlik	Filtre	Metot	Hedef
Feza-Base	ConvNeXt	PANet	T-head	(3, 3, 27, 3)	(96, 192, 384, 768)	TOOD	Patoloji tespiti
Feza-Small	ConvNeXt	PANet	T-head	(3, 3, 9, 3)	(96, 192, 384, 768)	TOOD	Hassas Patoloji Tespiti

*Tablo 1: Testler sonucunda en başarılı model versiyonlarının özellikleri*

Yukarıdaki tabloda backbone, neck ve head bölümünde aday algoritmalar arasından seçilen algoritmaların birleşimiyle oluşturulmuş model versiyonları vardır. Her iki model için kullanılan derinlik ve filtre sayıları görüldüğü gibidir. İki model arasındaki fark bu özelliklerdeki değişimdir. Feza-Small modeli Feza-Base modeline göre daha az derin ve daha az parametrelidir. Metot bölümünde, kullanılan eğitim metodu belirtilmiştir. Hedef sütununda ise modellerin tespit hedefleri belirtilmiştir.

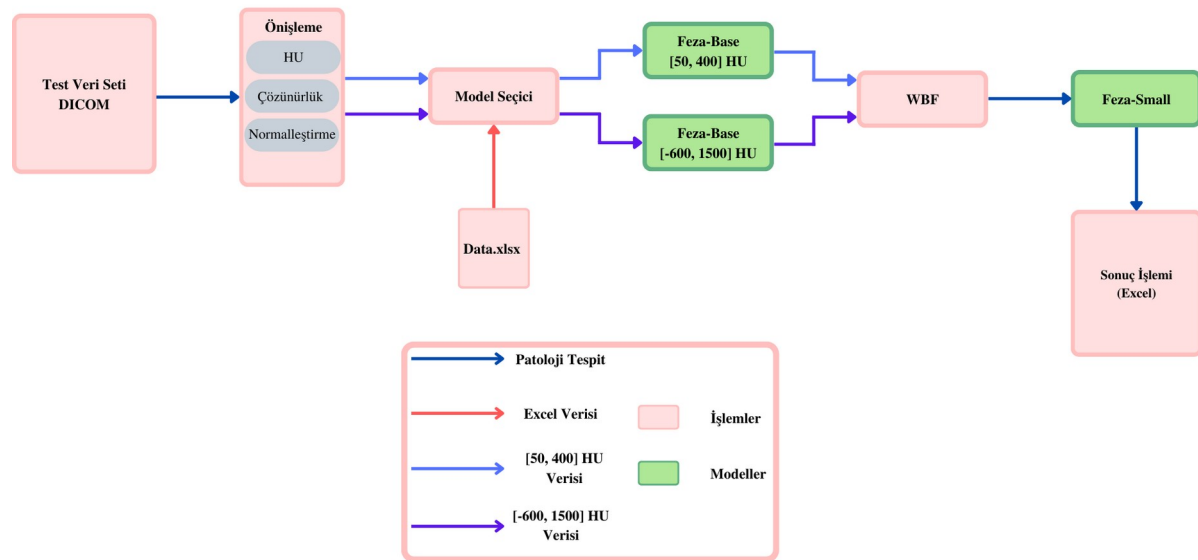
Proje sunuş raporunda tasarlanan modele, aynı görüntünün birden fazla HU değerleri ile elde edilen versiyonları çoklu girdi olarak verilmesi belirtilmişti ancak bu düşünceden vazgeçildi ve daha doğru sonuçlar elde etmek için farklı bir yöntem belirlendi. Yeni yöntemde veri setinin 2 farklı versiyonu oluşturulur. Bu versiyonlar bahsedilen [50, 400] ve [-600, 1500] HU değerlerine göre belirlenir. Aynı özelliklerde 2 farklı model oluşturulur ve belirtilen HU versiyonları ile ayrı ayrı eğitilir. Böylece modelin girdisi teke düşürülmüş olur ancak 2 farklı versiyonu elde edilir. Bu değişikliğin amacı eğitim ve test sırasında bellek kullanımını

azaltmak ve bu 2 farklı versiyonda eğitilmiş modellerin çıktılarını birleştirerek daha doğru patoloji tespiti sağlamaktır. Böylece her patoloji sınıfı için 2 farklı model kullanılmış olur.

2 modelin çıktılarını birleştirmede proje sunuş raporunda bahsedilen Weighted Boxes Fusion (WBF) [11] algoritması kullanıldı. Böylece ensemble modeller tasarlanmış oldu. Son zamanlarda algoritmaların tespit başarısını artırdığı kanıtlanan bu yöntem ile daha isabetli patoloji tespitleri yapıldı. Çalışma mantığı kısaca modellerden elde edilen koordinat ve sınıf çıktılarını belirlenen threshold ve ağırlıklara göre birleştirir. Böylece her modelin açığını kapatır ve daha doğru sonuçlar elde edilmesini sağlar.

Proje sunuş raporunda belirtilmeyen bir yöntem daha patoloji tespit algoritmasına eklendi. Yapılan analizlere göre tespit edilmesi beklenen patolojilerin boyutları çok küçük olduğu anlaşıldı. Bunun sonucunda tasarlanan modellerin koordinat çıktıları yeterince hassas olmadığı belirlendi. Bu problemi giderip daha hassas koordinat tahminleri elde edebilmek için yeni bir yöntem geliştirildi. Bu yöntemde tespit edilen patolojilerin çevresindeki belirli alan görüntüden kesilir, resize yöntemiyle büyütülür ve kesilmiş ve büyütülmüş görüntüde patolojinin tespiti farklı bir model kullanılarak tekrar yapılır. Böylece çok daha hassas ve gerçeğe daha yakın koordinat çıktısı alınmış olur. Bu yöntem patoloji tespit algoritmasına eklendikten sonra algoritmanın başarısının arttığı gözlemlenmiştir.

En son elde edilen koordinat tahminleri yarışma kapsamına uygun bir şekilde düzenlenir ve excel dosyasına yarışma tarafından belirlenmiş standartlara göre kaydedilir.



Şekil 1: Tasarlanan ve yarışmada kullanılacak olan patoloji tespit algoritması

Yukarıdaki figür tasarlanan patoloji algoritmasının çalışma mantığıdır. Yarışmada verilen DICOM test verileri ön işlemden geçirilir. DICOM verisinden pixel değerleri alınarak bilgisayarlı tomografi görüntüsü elde edilir. Görüntü çözünürlüğü ayarlanır. Eğitim ve test senaryolarında çözünürlük (640, 640) olarak belirlenmiştir. Daha sonra belirlenen HU aralıklarına göre görüntünün 2 farklı versiyonu elde edilir. İlk versiyon [50, 400] HU aralığına göre belirlendi çünkü sağlık bakanlığının sağlamış olduğu DICOM verilerinde en çok rastlanan HU aralığının [50, 400] olduğu saptanmıştır. İkinci versiyon [-600, 1500] HU aralığına göre belirlendi çünkü yapılan makale araştırmalarında bu aralığın patoloji tespiti için uygun olduğu saptandı. Daha sonra her iki görüntü versiyonu normalize edilerek model seçici algoritmasına gönderilir. Yarışma sırasında seri ve kesitlerin hangi bölgeyi içerdiği

bilgisi bir excel dosyasında verileceği ifade edilmişti. Model seçici algoritması görüntünün seri ve kesit bilgisine göre hangi bölgeyi içerdiği bilgisini Data.xlsx dosyasından çeker ve görüntü versiyonlarının 6 farklı patoloji sınıfı için eğitilen 6 modelden hangisine uygun olduğunu belirler ve en uygun modele görüntü versiyonlarını gönderir. Tasarlanan modellerin literatürde örneği olmadığı için Feza ismi verildi. Her iki HU aralığını içeren görüntü versiyonları ayrı olarak patoloji sınıfına uygun bir şekilde Feza-Base modeline verilir. İki farklı görüntü versiyonlarından elde edilen koordinat çıktıları WBF algoritmasına gönderilir. WBF algoritmasında bu çıktılar belirlenen threshold ve ağırlıklara göre birleştirilir ve sonuç olarak tek çıktı elde edilmiş olur. [50, 400] HU aralığında olan birinci görüntü versiyonundan WBF ile elde edilen koordinat çıktısı merkezde olacak şekilde 32X32'lik bir alan kesilir ve resize yöntemiyle 224X224 boyutuna çıkarılır. Daha sonra bu kesilmiş ve büyütülmüş görüntü Feza-Small modeline verilir ve daha hassas koordinat çıktıları elde edilir. Feza-Small modeli, Feza-Base modelinin daha az parametrelili ve daha az derin versiyonudur. Sonuç işleminde ise elde edilen koordinat çıktısı orijinal görüntü boyutuna göre tekrar hesaplanır. Yarışmanın beklediği standartlara göre elde edilen sonuçlar sonuç excel dosyasına kaydedilir.

## 2. ÖZGÜNLÜK

Yarışma kapsamına uygun en iyi patoloji tespit algoritması tasarlanırken tamamen özgün olmak hedeflendi. Hazır olarak bulunan nesne tespit modelleri kullanmaktan kaçınıldı ve daha önce yapılmış çözümler yerine onları geliştirmeye ve daha doğru yeni çözümler getirmeye uğraşıldı.

Özgün bir algoritma tasarlayabilmek ve problemin çözümünde kullanmak üzere literatürde olmayan yeni modeller tasarlandı. Proje sunuş raporunda bahsedilen ve sonrasında tasarlanan backbone-neck-head kombinasyonları denendi ve yarışma tarafından verilen problemin çözümüne en uygun model tasarlanmış oldu. Literatürde, tasarlanan modelin bir örneği olmadığı için modele Feza ismi verildi. Bu model tasarlanırken en güncel, en başarılı ve göreve en uygun algoritmaların kullanılmasına özen gösterildi.

Problemi en doğru şekilde çözmek için okunan makalelerden alınan örneklerle farklı HU aralıkları kullanıldı. Ancak makalelerden öğrenilen yöntemler birebir kullanılmadı, bu yöntemler geliştirildi ve başarıyı daha çok artıran yöntemler elde edilmiş oldu. Okunan makalelerde belirlenen HU aralıkları modele tek seferde çoklu girdi olarak veriliyordu. Yapılan değişiklikle farklı HU aralıkları çoklu girdi olarak değil, kendisi için özel eğitilmiş modele tek girdi olarak verildi. Böylece eğitim ve test sırasında kullanılan bellek miktarı azaltıldı ve HU aralıklarıyla test edilen modellerin çıktıları birleştirilerek daha doğru sonuçlar elde edildi.

Feza modelini oluşturmak için backbone olarak denenilen açık kaynaklı VAN ve ConvNeXt, normalde sınıflandırma algoritmalarıdır. Probleme uygun hale getirebilmek için tam bağlantılı katmanları silindi ve çeşitli düzenlemeler yapılarak MMDetection sistemine entegre edilebilecek hale çevrildi. Ayrıca proje sunuş raporuna uygun olmak üzere birden fazla çıkış alınabilecek şekilde kodları tekrar düzenlendi. Böylece her iki algoritma da patoloji tespit algoritmalarında kullanılabilecek backbone algoritmasına dönüştürüldü.

Patoloji tespitinde ensemble model tasarımı kullanıldı. Feza-Base modellerinden elde edilen çıktılar son dönemde nesne tespit algoritmalarında başarıyı artırdığı kanıtlanan WBF yöntemiyle birleştirildi. Böylece patoloji tespitinde ensemble modellerde WBF kullanılarak literatüre yeni bir bakış açısı kazandırılmış oldu.

Sağlık bakanlığı tarafından sağlanan veri setindeki DICOM verileri, çözümü beklenen patoloji sınıflarına göre ayrı olarak değerlendirildi. Patoloji sınıfları için aynı özellikte farklı

modeller eğitildi. Görüntü kesitlerinin hangi bölgede olduğu bilgisi yarışma sırasında verileceği için bu yöntem tasarlandı. Böylece görev odaklı ve özgün bir algoritma tasarımı ortaya çıktı. Bu sayede yanlış patoloji sınıfı tespitinin önüne geçilmiş ve algoritma başarısı artırılmış oldu.

Sağlık bakanlığının sağladığı veri setinde bazı patoloji sınıflarının görüntü sayısı az olarak görüldü. Bu problemi çözmek için literatürde açık kaynaklı olarak bulunamayan yeni bir çoğaltma algoritması geliştirildi. Bu çoğaltma algoritmasının en büyük özelliği görüntüleri ve o görüntülerin etiket dosyalarını birbirlerine uyumlu bir şekilde çoğaltabilmesidir.

Yarışma sırasında kullanılacak ve yukarıdaki figürde gösterilen patoloji tespit algoritması, tamamen özgün bir şekilde tasarlanmıştır. Patoloji algoritması tasarlanırken tamamen görev odaklı, güncel ve başarılı olmaya özen gösterilmiştir. Patolojilerin tespitini hassas bir şekilde yapmak için uygulanan yöntem literatüre kazandırılmıştır. Daha önce de belirtildiği gibi bu yöntemde tespiti yapılan patoloji alanı görüntüden kesilir, belirli oranlarda büyütülür ve tekrar patoloji tespiti yapılır. Uygulanan bu yöntem, patoloji tespit algoritmasının başarısını artırmıştır. Literatürde bulunmayan bu gibi çözüm yöntemleri açıklanan patoloji algoritmasında kullanılarak özgün bir algoritma tasarlanmıştır.

### 3. SONUÇLAR VE İNCELEME

Literatürde bulunmayan, özgün ve görev odaklı bir patoloji tespit algoritması hedeflendiği için birçok testler yapıldı. Patoloji tespit algoritması için oluşturulan model kombinasyonları denendi ve göreve en uygun model kombinasyonu seçildi.

Backbone	Neck	Head	Hafıza Kullanım (Mb)	Sınıf Kayıp (%)	Bbox Kayıp (%)	Eğitim Süresi (dk)	Test Süresi (sn)	bbox-mAP 50	bbox-mAP
VAN	FPN	T-head	1320	0.122	0.529	22	43	0.68	0.23
ConvNeXt	FPN	T-head	1668	0.084	0.454	39	76	0.775	0.296
ConvNeXt	BiFPN	T-head	1856	0.26	0.52	78	152	0.371	0.143
ConvNext	FPN	YOLO-head	986	0.32	0.65	42	110	0.264	0.10
ConvNeXt	PANet	T-head	2342	0.06	0.45	65	101	0.786	0.326

Tablo 2: Model kombinasyonlarının başarı testi sonuçları

Yukarıdaki tablo, denenmiş olan backbone-neck-head kombinasyonlarının başarı sonuçlarıdır. Bu test yapılırken veri seti olarak sağlık bakanlığının sağlamış olduğu veri setinden alınan böbrek taşı patolojisi içeren görüntüler kullanılmıştır. Veri seti 1719 görüntüden oluşuyordu. Daha önce bahsedilen özgün olarak tasarlanmış çoğaltma algoritması kullanılarak görüntü sayısı 5141'e çıkarılmıştır. Görüntülerin 4683 tanesi eğitim, 458 tanesi test olacak şekilde bölünmüştür. Tüm model kombinasyonları MMDetection ortamında birleştirilmiş ve eğitimleri yine bu platformda yapılmıştır. Tabloda backbone, neck ve head bölümleri aday algoritmaları belirtir. Hafıza kullanımı bölümü, bahsedilen veri setiyle eğitilen model kombinasyonunun donanımsal olarak Megabyte cinsinden harcadığı bellek miktarını gösterir. Sınıf kayıp sütunu eğitim sonunda modelin yüzde kaç kayıp ile sınıflandırma yapabildiği, bbox kayıp sütunu ise eğitim sonunda modelin yüzde kaç kayıp ile koordinatları IoU cinsinden bulabildiğini gösterir. Her model kombinasyonu için 1 epoch'luk eğitimi kaç dakikada tamamladığı eğitim süresi sütunundan bakılabilir. Ayrıca 458 test

görüntüsünün kaç saniyede test edildiği bilgisi test bölümünden okunabilir. Bbox-mAP 50 sütunu IoU threshold 0.5 olduğu zaman gerçek koordinatlar ile tahmin edilen koordinatların arasındaki doğruluk oranını, bbox-mAP ise gerçek koordinatlar ile tahmin edilen koordinatlar arasındaki doğruluk oranını gösterir.

Yapılan denemelerin sonuçlarına göre en iyi model kombinasyonu seçildi. Backbone adaylarından VAN, ConvNeXt'e göre hızlı olsa bile başarı anlamında daha zayıf olduğu için backbone olarak ConvNeXt seçilmiştir. BiFPN ve PANet arasında yapılan değerlendirmede hem hız hem de başarı açısından PANet daha üstün performans gösterdiği için patoloji tespit modelinde neck olarak kullanılmak üzere seçilmiştir. Head adaylarından T-head ve YOLO-head algoritma başarılarına bakıldığında, YOLO-head bellek kullanımı açısından çok iyi olsa da başarı açısından T-head algoritmasının çok gerisinde kalmıştır. Bu sebepten dolayı T-head patoloji tespit modelinde head olarak kullanılmak üzere seçilmiştir. Algoritma seçimleri yapılırken öncelik bbox-mAP doğruluğuna verilmiştir. Hız ve bellek kullanımı gibi diğer parametreler ikinci planda olacak şekilde değerlendirilmiştir. Sonuç olarak patoloji tespitinde kullanılmak üzere seçilen model kombinasyonu ConvNext, PANet ve T-head olarak belirlenmiştir. Literatürde bu modelin bir örneği olmadığı için modele Feza ismi verilmiştir.

Model	Veri Seti	Hız (it/s)	bbox-mAP 50	bbox-mAP
Feza-Base	Patoloji Tespiti	4.5	0.786	0.326
Feza-Small	Hassas Patoloji Tespiti	5.09	0.891	0.428

*Tablo 3: Tasarlanan ve seçilen modellerin patoloji tespit testi başarıları*

Yukarıdaki tablo patoloji tespit algoritmasında kullanılan modellerin bilgilerini içerir. Veri seti bölümü, test için kullanılan veri setlerinin görev olarak hangi özelliğe göre seçildiğini, hız bölümü modellerin saniyede kaç görüntü (iteration/second) işleyebildiğini gösterir. Bbox-mAP bölümleri ise yukarıda belirtildiği gibi test verisiyle yapılmış testlerde gerçek koordinatlar ile tahmin edilen koordinatlar arasındaki doğruluk oranını gösterir.

Her iki modelin testinde de yukarıda bahsedilen böbrek taşı veri seti kullanıldı. Feza-Base modelinde görüntülerin [50, 400] HU aralığındaki orijinal halleri kullanıldı. Çıktı olarak elde edilen koordinat bilgileri merkezde olacak şekilde görüntüden 32X32'lik alan koparıldı ve boyutu 224X224'e çıkarıldı. En sonunda koparılıp işlenen görüntü hassas patoloji tespiti yapan Feza-Small modeline verildi. Tabloda görüldüğü üzere Feza-Small modelinden elde edilen koordinat çıktıları başarı oranını ciddi ölçüde artırdı.

Yarışma kapsamında belirlenen patoloji tespit problemini çözmek için birçok zorlukla mücadele edildi. Literatürde olmayan yeni modeller tasarlandığı için backbone, neck ve head gibi model bölümlerinde uyumsuzluk sorunları açığa çıktı. Model kombinasyonları oluşturulurken uyumsuzluk yüzünden eğitimler yapılamıyordu. Seçilen algoritmalar açık kaynaklı olduğu için uyum sorunlarını gidermek adına kodlarında düzenlemeler yapıldı. VAN ve ConvNeXt algoritmalarının tam bağlı katmanları silindi ve neck bölümüne uygun olması açısından tüm katmanlarından çıkış alınabilecek şekilde düzenlendi. Ayrıca bu algoritmalar MMDetection sistemine entegre edilebilecek hale getirildi. BiFPN algoritması denenirken aktivasyon fonksiyonu hesaplama hatalarıyla karşılaşıldı. Bu hataları gidermek adına algoritmanın bazı ReLu aktivasyonu hesaplama kısımları "inplace" durumundan



çıkarılarak tekrar düzenlendi ve hata giderildi. Bir başka karşılaşılan sorun donanımsal sınırlardı. Ekran kartı olarak Nvidia GTX 1650 4GB kullanıldı ve eğitim sırasında CUDA bellek yetersizliği sorunu ile karşılaşıldı. Bu durumu çözmek için tasarlanan algoritmaların parametre sayısı düşürüldü, derinliği azaltıldı ve eğitim sırasındaki görüntü çözünürlüğü donanımın sınırlarına uygun şekilde seçildi. Model eğitimleri COCO standartlarına göre gerçekleştirildi çünkü MMDetection sistemi bu standartlara uyulmasını bekliyordu. Veri setini bu standartlara göre oluştururken bir hata yapıldı. Gerçek etiket dosyalarında sınıflar indeks olarak 0'dan başlanarak sıralandırıldı. Bu şekilde eğitim yapıldığında çok kötü sonuçlar elde ediliyordu. Daha sonra fark edildiği üzere COCO standartlarında sınıf indeksleri 0'dan değil 1'den başlamalıydı. Bu hata giderildikten sonra sağlıklı eğitimler yapılabilirdi. Yarışma kapsamında verilen patoloji tespit problemini en doğru şekilde çözüme ulaştırmak için birçok yöntem ve algoritma tasarlandı. Göreve en uygun ve güncel algoritmalar ve yöntemler araştırılarak ve test edilerek büyük bilgi birikimi sağlandı. Literatürde bulunmayan yeni başarılı modeller geliştirildi ve görev odaklı ve özgün patoloji tespit algoritması tasarlanarak büyük tecrübeler edinildi.

#### 4. DENEY VE EĞİTİM AŞAMALARINDA KULLANILAN VERİ SETLERİ

Deney ve eğitim aşamasında sağlık bakanlığının sunduğu veri seti kullanıldı. Bu veri seti, abdomen bölgesini içeren DICOM serilerinden ve bu seriler ile ilgili bilgileri içere data exel dosyasından oluşur. Toplam 38236 DICOM verisi mevcuttur. Bu verilerin 37888 tanesi etiketli 5348 tanesi etiketsizdir. Veriler 17 sınıfa aittir. Yarışma tarafından verilen bilgiler ışığında bulunması beklenen 6 patoloji türüne öncelik verilmiştir. Diğer sınıflar ikinci planda değerlendirilmiştir. Ayrıca etiketsiz veriler patoloji içermeyen normal veriler olarak değerlendirilmiştir.

Sınıflar	Etiketsiz (Adet)	Etiketli (Adet)	Öncelik	Patoloji Sınıfı	Sınıflar	Etiketsiz (Adet)	Etiketli (Adet)	Öncelik	Patoloji Sınıfı
Akut divertikül ile uyumlu	4	1148	1	5	Akut apandisit ile uyumlu	432	5559	1	1
Kalsifiye divertikül	2	73	2	-1	Apendikolit	66	293	2	-1
Abdominal aort anevrizma	6	9003	1	6	Böbrek taşı	114	1928	1	4
Akut kolesistit ile uyumlu	228	4925	1	2	Safra kesesi taşı	94	1594	2	-1
Akut pankreatit ile uyumlu	2196	4925	1	3	Pankreas	632	0	2	-1
Abdominal aort diseksiyon	0	814	1	6	Kolon	688	0	2	-1
Safra Kesesi	594	0	2	-1	Böbrek-Mesane	876	0	2	-1
Apandiks	468	0	2	-1	Abdominal Aorta	852	0	2	-1
Üreter taşı	98	628	1	4					

Tablo 4: Sağlık bakanlığı veri seti analizi

Yukarıdaki tabloda sınıflar bölümü veri setinde bulunan sınıfları, etiketsiz sütunu koordinat bilgisi içermeyen görüntü sayısını, etiketli sütunu koordinat bilgisi içeren görüntü sayısını belirtir. Öncelik sütunu ise yarışma tarafından tespit edilmesi beklenen patoloji sınıflarına göre seçilmiştir. Önceliği 1 olan sınıflar daha önemlidir. Patoloji sınıfı bölümünde ise yarışma tarafından belirlenen 6 patoloji sınıfından hangisi ile uyumlu olduğunu indeks

numarasına göre belirtir. Yarışma tarafından belirlenen patoloji sınıfları sıralı şekilde akut apandisit, akut kolesistit, akut pankreatit, böbrek/üreter taşı, akut divertikülit, aorta anevrizma/diseksiyon olarak sınıflandırılabilir. Patoloji sınıfı -1 olanlar ise yarışma tarafından bulgusu beklenmeyen ama tespiti beklenen sınıflara yardımcı olabilecek sınıflardır.

Sağlık bakanlığının sağlamış olduğu veri seti dışında Deeplesion [12] veri seti eğitim aşamalarında kullanıldı. Deeplesion veri seti 32120 bilgisayarlı tomografi görüntülerinden oluşan tamamen açık kaynaklı bir veri setidir. Bu yüzden herhangi bir izin ile uğraşılmamıştır. Bu görüntüler Kemik, karın, mediasten, karaciğer, akciğer, böbrek, yumuşak doku ve pelvis sınıflarından oluşur. Tüm görüntüler orijinal HU değerlerine göre işlenmiş png verilerinden oluşur. Görüntü boyutları 512X512'dir. Bu veri setinin amacı belirtilen sınıflardaki patolojilerin tespit edilmesidir. Sağlık bakanlığı veri setine benzer şekilde bir csv dosyası içerir. Bu csv dosyasında görüntüler hakkında çeşitli bilgiler vardır. Örnek olarak görüntü sahibinin cinsiyeti, yaşı, görüntünün kesit indeksi, hangi sınıfa ait olduğu ve eğer varsa patolojinin koordinatlarını gösterir. Yarışma kapsamına uygun ve görev odaklı olmak açısından bu veri setinde sadece abdomen sınıfı kullanılmıştır. Tüm abdomen patolojileri tek bir sınıf içerisinde incelendiği için bu veri seti sadece eğitimde kullanılmıştır. Bu veri setinde toplamda 2176 abdomen görüntüsü ve bu görüntülerin patoloji koordinat bilgileri mevcuttur. Feza-Base modeli sağlık bakanlığı verileriyle eğitilmeden önce Deeplesion veri setinde bulunan abdomen sınıfı ile eğitilir ve böylece Feza-Base modeli daha güçlü hale getirilir. Daha sonra pretrained olacak şekilde daha önce belirtilen standartlarda sağlık bakanlığı verileriyle Feza-Base modelleri eğitilir. Bu sayede eğitim süresinin kısaltılması ve genelleme performansı yüksek bir model eğitilmesi amaçlanmıştır.

## 5. REFERANSLAR

- (1) Chen, K., Wang, J., Pang, J., Cao, Y., Xiong, Y., Li, X., ... & Lin, D. (2019). MMDetection: Open mmlab detection toolbox and benchmark. arXiv preprint arXiv:1906.07155.
- (2) Guo, M. H., Lu, C. Z., Liu, Z. N., Cheng, M. M., & Hu, S. M. (2022). Visual attention network. arXiv preprint arXiv:2202.09741.
- (3) Liu, Z., Mao, H., Wu, C. Y., Feichtenhofer, C., Darrell, T., & Xie, S. (2022). A ConvNet for the 2020s. arXiv preprint arXiv:2201.03545.
- (4) Tan, M., Pang, R., & Le, Q. V. (2020). Efficientdet: Scalable and efficient object detection. In Proceedings of the IEEE/CVF conference on computer vision and pattern recognition (pp. 10781- 10790).
- (5) Liu, S., Qi, L., Qin, H., Shi, J., & Jia, J. (2018). Path aggregation network for instance segmentation. In Proceedings of the IEEE conference on computer vision and pattern recognition (pp. 8759-8768).
- (6) Feng, C., Zhong, Y., Gao, Y., Scott, M. R., & Huang, W. (2021, October). Toood: Task-aligned onestage object detection. In 2021 IEEE/CVF International Conference on Computer Vision (ICCV) (pp. 3490-3499). IEEE Computer Society.
- (7) Redmon, J., & Farhadi, A. (2018). Yolov3: An incremental improvement. arXiv preprint arXiv:1804.02767.
- (8) DenOtter, T. D., & Schubert, J. (2019). Hounsfield Unit.

- (9) Dharneeshkar, J., Aniruthan, S. A., Karthika, R., & Parameswaran, L. (2020, February). Deep Learning based Detection of potholes in Indian roads using YOLO. In 2020 International conference on inventive computation technologies (ICICT) (pp. 381-385). IEEE.
- (10) Lin, T. Y., Maire, M., Belongie, S., Hays, J., Perona, P., Ramanan, D., ... & Zitnick, C. L. (2014, September). Microsoft coco: Common objects in context. In European conference on computer vision (pp. 740-755). Springer, Cham.
- (11) Solovyev, R., Wang, W., & Gabruseva, T. (2021). Weighted boxes fusion: Ensembling boxes from different object detection models. *Image and Vision Computing*, 107, 104117.
- (12) Yan, K., Wang, X., Lu, L., & Summers, R. M. (2018). DeepLesion: automated mining of large-scale lesion annotations and universal lesion detection with deep learning. *Journal of medical imaging*, 5(3), 036501.